



# **CHALLENGE C**

## **QUARTO (.QMD)**

Building an LLM knowledge base for the electrical-energy domain.

ECI CLUSTER



# Agenda

**01**

Contexto e Desafio

**02**

Implementação e Métodos

**03**


Resultados

**04**

Discussão e Conclusão

**05**

Trabalho Futuro



# 01

## **Contexto e Desafio**

O padrão de wiki mantida por LLM e o Challenge C

# O Desafio Challenge C(oimbra)

- Coimbra → Challenge C: Apresentar o conhecimento como ficheiros Quarto .qmd e renderizar um site HTML navegável + índice llms.txt para IA
- Arquitetura:
  - artifacts/ — PDFs imutáveis, o LLM só lê
  - wiki/ — camada que o LLM escreve e mantém
  - schema (CLAUDE.md + .claude/) — regras fixas a seguir
- 3 operações centrais: ingest, lint, query (nomes livres, função fixa)
- Corpus: 5 especificações do UK Smart Energy Code (DUI5, SMKI Appendix M/N/P, GBCS) — ~6 a ~400 páginas cada, fortemente inter-referenciadas



# 02

## **Implementação e Métodos**

O corpus SEC, as estruturas candidatas e o desenho experimental

# .md simples vs. .qmd (Quarto)

| Critério                | Markdown simples (.md)            | .qmd (Quarto)                                  |
|-------------------------|-----------------------------------|------------------------------------------------|
| Portabilidade           | Total — texto puro                | Total — continua a ser Markdown                |
| Front matter validável  | Livre, sem validação nativa       | YAML + /lint mecânico (enums, ranges, links)   |
| Site navegável          | Não (precisa de ferramenta extra) | Nativo: quarto render → sidebar, listing pages |
| Índice p/ IA (llms.txt) | Tem de ser construído à mão       | Nativo: llms-txt: true gera tudo               |
| .llms.md por página     | Não existe                        | Gerado automaticamente por página              |
| Toolchain exigido       | Nenhum                            | CLI Quarto + passo de render                   |

Conclusão: o .qmd não sacrifica nenhuma vantagem do Markdown simples — é Markdown com uma camada de renderização e de geração de índice de IA nativas, ao custo de um toolchain adicional e de um passo de render explícito.

## Metodologia Estatística

- Avaliação sempre feita "a frio": o agente recebe só o índice lms.txt e a pergunta, e decide sozinho o que ler — o cenário que reflete o uso real do /query
- Comparações independentes (estrutura vs. estrutura, schema vs. schema): teste de Mann-Whitney U + teste t de Welch + d de Cohen, n=46 por braço
- Comparações emparelhadas (esforço de raciocínio, 3 níveis): teste de Friedman (omnibus) + Wilcoxon par-a-par, correção de Bonferroni ( $\alpha=0,05/3\approx0,0167$ )
- Centenas de corridas de agentes ao longo do projeto para sustentar cada decisão de arquitetura com dados, não só argumento

Critérios: 1. Accuracy das respostas 2. Gastos Tokens

# As Três Estruturas Candidatas

```
wiki/  
  documents/  
  concepts/  
  glossary.qmd  
  index.qmd
```

**Estrutura A**

```
wiki/  
  dcc-user-interface/  
    overview.qmd  
    concepts.qmd  
  smki-interface-design/  
    overview.qmd  
    concepts.qmd  
  ...
```

**Estrutura B**

```
wiki/  
  security/           # SMKI, certificados, chaves  
  connectivity/       # DCC, interfaces, mensagens  
  compliance/         # Code of Connection, Companion Spec  
  glossary.qmd
```

**Estrutura C**

A vs. B vs. C — Custo Real, Testado a Frio (n=46)

| Estrutura            | Ficheiros lidos | Tokens         | Latência (ms)  |
|----------------------|-----------------|----------------|----------------|
| A — Híbrida          | 5,6 ± 1,3       | 35 297 ± 1 088 | 27 626 ± 5 203 |
| B — Por Documento    | 8,4 ± 0,7       | 35 254 ± 660   | 28 877 ± 4 754 |
| C — Plana (baseline) | 5,0 ± 1,2       | 34 206 ± 1 410 | 26 622 ± 7 527 |

Significância par-a-par (Mann-Whitney U / Welch t, n=46 por braço)

| Comparação | Ficheiros (p)  | Tokens (p)     | Latência (p)     |
|------------|----------------|----------------|------------------|
| A vs. B    | p<0,0001 — SIM | p=0,082 — NÃO  | p=0,241 — NÃO    |
| C vs. A    | p=0,0006 — SIM | p=0,0001 — SIM | p=0,047 — limite |
| C vs. B    | p<0,0001 — SIM | p<0,0001 — SIM | p=0,004 — SIM    |

C é significativamente mais barata em tokens do que A e B, com um agente genérico sem instrução especial — porque encontra a síntese da Estrutura A mas não confia nela sozinho, e relê as fontes primárias na mesma.

# Com o /query Real, a Estrutura A Vence

| Estrutura | Ficheiros lidos (produção) | Cobertura | Sig. vs. as outras 2 |
|-----------|----------------------------|-----------|----------------------|
| A         | 3,04 ± 0,29                | 100%      | p≈0 — SIM            |
| B         | 8,93 ± 0,49                | 100%      | p≈0 — SIM            |
| C         | 6,00 ± 0,00                | 100%      | p≈0 — SIM            |

As 3 comparações par-a-par (Welch t): A vs. B t=-69,87; A vs. C t=-68,00; B vs. C t=40,62 — todas p≈0, sem sobreposição entre distribuições (n=46 por braço). Uma instrução explícita no /query — 'confia na síntese, não reverifiques' — muda tudo: A cai de 5,6 para 3,04 ficheiros (-46%). A estrutura de pastas e a instrução de confiança do /query NÃO são decisões separáveis.

# Schema v1 (base) vs. Schema v2

|                                         | Schema v1                                                          | Schema v2                                             | p-value — Significativo? |
|-----------------------------------------|--------------------------------------------------------------------|-------------------------------------------------------|--------------------------|
| Campos                                  | title, type, categories, last-ingested, source-pdf, source-version | + status, confidence-score, supersedes, last-verified | —                        |
| Uso confiante de valor desatualizado    | 89%                                                                | 16%                                                   | p=0,000008<br>SIM        |
| Conflito não resolvido sinalizado       | 28,9%                                                              | 79,5%                                                 | p=0,0000016<br>SIM       |
| Hedging com baixa confiança (score 0,3) | 88,9%                                                              | 100%                                                  | p=0,024<br>SIM           |
| Reduz custo (tokens/ficheiros)?         | —                                                                  | Não — é o /query                                      |                          |

```
title: "..."  
type: document # ou concept / glossary  
source-pdf: ".../pdfs/<ficheiro>.pdf" # só documentos  
source-version: "..." # só documentos  
categories: [...]  
related: [...] # se aplicável  
last-ingested: <data de hoje>  
status: draft # nova ingestão começa "draft" até ser revista; usar "verified" só  
# depois de confirmar a extração contra o PDF  
confidence-score: <0.0-1.0> # honesto: quão diretamente o texto reflete o PDF vs. inferência tua  
supersedes: [] # ou [caminho(s)] se substituir página(s) existente(s)  
last-verified: <data de hoje, ou omitir se ainda for draft>
```

Achado-chave: o schema v2 não torna o /query mais barato (diferença NÃO significativa) — torna-o mais correto e honesto perante informação desatualizada ou em conflito (diferenças SIM significativas). Custo e correção são alavancas independentes.

# Cristalização: Como o /query "Aprende"

*Se responder exigiu cruzar mais do que uma página, essa síntese é guardada de volta na wiki — sem custar a mesma pesquisa duas vezes*

1

## Gatilho

A resposta cruzou mais do que uma página (documents/ e/ou concepts/). Uma leitura direta de 1 página existente não dispara nada.

2

## Verificação de duplicação

Antes de escrever, lê o CORPO (não só título/categories) de todos os concepts/\*.qmd sobrepostos: "já existe uma página que diz substancialmente isto?"

3

## Decide o destino

Página próxima já existe e fica com  $\leq 3$  fontes? Atualiza-a. Senão, cria concepts/<novo>.qmd, com related a apontar para as páginas usadas.

4

## Grava sem pedir confirmação

Decisão do utilizador: a verificação do passo 2 é a única salvaguarda contra páginas redundantes.

5

## Avisa no fim da resposta

Nota curta: "Guardei esta síntese em concepts/X.qmd, por ter cruzado N páginas para responder."

Exemplo real: concepts/capacity-management.qmd nasceu de uma pergunta que comparou os limites de capacidade SMKI vs. DUIS. confidence-score: 0,55. Mais baixo do que qualquer página-fonte individual, porque metade da comparação era uma lacuna reconhecida (dados do DUIS nunca ingeridos), não incerteza sobre as fontes lidas.



# 03

## **Resultados**

Custo, qualidade, esforço de raciocínio e a comparação final

# Wiki (Quarto) vs. PDFs em Bruto

|                    | Accuracy      | Tokens / pergunta | Total (25 perguntas)     |
|--------------------|---------------|-------------------|--------------------------|
| Só PDFs (sem wiki) | 24,5/25 (98%) | 57 042            | 1 426 047                |
| Wiki (Quarto)      | 25/25 (100%)  | 39 194            | 979 848                  |
| Diferença          | —             | +45,5% sem wiki   | +446 199 tokens sem wiki |

25 perguntas, cada uma respondida uma vez em cada condição (n=1, sem oráculo): um agente só com os 5 PDFs em pdfs/ vs. um agente só com a wiki. Tokens reais (subagent\_tokens), não estimados. SEM TESTE DE SIGNIFICÂNCIA: n=1 por pergunta/condição não permite estimar variância nem calcular p-value — diferença descritiva.

# Onde a Wiki Realmente Compensa

| Categoria                                               | Só PDFs (média) | Wiki (média) | Diferença              |
|---------------------------------------------------------|-----------------|--------------|------------------------|
| Trivial<br>(14 perguntas — facto num só documento)      | 37 196          | 38 831       | PDFs ~4% mais baratos  |
| Não-trivial<br>(11 perguntas — síntese cross-documento) | 82 300          | 39 656       | Wiki 2,08× mais barata |

Sem teste de significância (n=1 por pergunta/condição) — diferenças descritivas, não confirmadas estatisticamente. Para um facto isolado num documento curto, ler o PDF direto é tão barato como a wiki; é nas perguntas cross-documento que a wiki compensa claramente — 4 das 25 perguntas "só PDFs" custaram sozinhas 146 929 a 176 279 tokens cada.

# Esforço de Raciocínio — Custo vs. Precisão (n=25) - Modelo Sonnet

| Comparação      | Tokens (p)      | Tempo (p)        |
|-----------------|-----------------|------------------|
| Baixo vs. Médio | p=0,032 — NÃO*  | p=0,00011 — SIM  |
| Baixo vs. Alto  | p=0,0018 — SIM  | p<0,000001 — SIM |
| Médio vs. Alto  | p=0,00073 — SIM | p=0,013 — NÃO*   |

*\* não sobrevive à correção de Bonferroni ( $\alpha=0,0167$ ) — Friedman omnibus SIM em ambos (tokens p=0,00011; tempo p=0,000001)*

- Precisão (66,7% → 75,0% → 87,5%): Q de Cochran p=0,042 (omnibus nominal), mas NENHUM par sobrevive a Bonferroni — baixo vs. alto fica mais perto (p=0,0625) — NÃO confirmado estatisticamente
- Só 1 alucinação em 15 respostas-armadilha, sempre no nível baixo
- Benchmark externo de 20 perguntas verificado contra os PDFs: 20/20 corretas — com ressalva de honestidade (mesmo conjunto usado para calibrar a ingestão)

## /ingest Ingerir um PDF novo (ou versão revista)

[caminho do PDF em pdfs/]

Converte um PDF em página(s) .qmd seguindo a Estrutura A e o schema completo

— nunca altera o PDF original, que permanece a fonte imutável.



## /lint Validar a wiki inteira

Lê os `.qmd` de origem (não os `.LLms.md` renderizados), reporta todos os problemas agrupados por tipo. Nunca corrige sozinho.

todas as  
wiki/\*.`qmd`

1



### Front matter obrigatório

title/type/categories/last-ingested sempre; documentos também source-pdf/source-version.

2



### Schema v2

status (enum de 4), confidence-score (0-1), supersedes (paths existentes), last-verified  $\geq$  last-ingested. Um dos 4 campos usado  $\rightarrow$  avisa se faltam os outros.

3



### Coerência entre páginas

Toda página stale/deprecated precisa de alguém a supersedes-la. Factos divergentes sem supersedes, ou conceitos duplicados sem se citarem, são avisos de deriva/redundância.

4



### Links e referências

Links relativos entre `.qmd` têm de existir. Toda página document precisa de link rastreável de volta ao PDF.

5




### Relatório final

Nº de ficheiros, erros bloqueantes vs. avisos heurísticos. Nenhuma correção sem confirmação prévia.

relatório  
erros + avisos

## /query Responder usando só a wiki [pergunta]

*Nunca usa os PDFs originais nem conhecimento próprio do domínio — só o que está ingerido em wiki/. Se a wiki não souber, diz que não sabe.*





# 04

## **Discussão e Conclusão**

O que os resultados significam, e o que ainda não sabemos

# A Configuração Final Escolhida

Com base em todos os testes anteriores — decidida pelos dois critérios: accuracy das respostas e gasto de tokens

## ESTRUTURA

### Estrutura A

Híbrida — vence com o /query real: 3,04 ficheiros lidos e 100% de cobertura

## SCHEMA

### Schema v2

Proveniência: uso de valor desatualizado cai de 89% para 16%; conflitos sinalizados a 79,5%

## MODELO

### Sonnet · esforço alto

Precisão 66,7% → 75% → 87,5%; nível alto sem alucinações nas perguntas-armadilha

## CRITÉRIO 1 — ACCURACY DAS RESPOSTAS


A + v2 + esforço alto entregam o teto de qualidade: 100% de cobertura na recolha, respostas honestas perante dados desatualizados ou em conflito, e 87,5% de precisão no nível alto. A wiki completa responde 25/25, contra 24,5/25 só com os PDFs.

## CRITÉRIO 2 — GASTO DE TOKENS

A Estrutura A é a mais eficiente em produção (3,04 ficheiros, -46% vs. teste a frio) e o schema v2 não acrescenta custo — são alavancas independentes. A wiki gasta 39 194 tokens/pergunta contra 57 042 só-PDFs (-31%). O esforço alto é o custo assumido em troca de precisão.

## O Que Aprendemos

- "Melhor estrutura" não é uma propriedade isolada de pastas — depende inteiramente de como o /query está instruído a confiar (ou não) nas suas próprias sínteses
- Correção/honestidade (schema v2) e eficiência de custo (instrução do /query) são alavancas independentes — não confundir uma com a outra
- Para documentos grandes, o teto de qualidade é a profundidade de ingestão — mais esforço de raciocínio no /query não compensa uma síntese incompleta
- Inconsistências dentro da própria fonte primária (não entre páginas da wiki) são um caso novo: o comportamento certo é documentá-las, não arbitrar uma resposta



**05**

## **Trabalho Futuro**

Future features & Nice to have

# Trabalho Futuro

- PRIORITÁRIO — pesquisar ferramentas de extração PDF → estruturado alternativas ao markdown (Docling, Marker, MinerU), que preservem headings/tabelas e possam reduzir os tokens gastos na ingestão e na síntese, face à extração de texto plano atual
- Repetir o benchmark de accuracy com um conjunto de perguntas não testadas
- Alargar a amostra do teste de esforço de raciocínio (~50–100 perguntas) para confirmar estatisticamente o ganho de precisão sugerido
- Nova heurística de /lint para inconsistências de nomenclatura dentro da própria fonte primária

**Q&A**

